

$$t_n = \phi(x_n) w^T + \eta_n \quad \text{con } \{t_n \in \mathbb{R}, x_n \in \mathbb{R}^P\}_{n=1}^N$$

$$w \in \mathbb{R}^Q \quad \phi: \mathbb{R}^P \rightarrow \mathbb{R}^Q \quad Q \geq P \quad y$$

$$\eta_n \sim N(\eta_n | 0, \sigma_\eta^2)$$

Presente el problema de optimización (inferencia) para

- Mínimos Cuadrados
- Mínimos Cuadrados Regularizados
- Máxima verosimilitud
- Máxima a posteriori
- Bayesiano

Mínimos Cuadrados

$$t = \phi(x_n) w^T + \eta_n \quad \begin{array}{l} \text{No prior} \\ \text{No Bayes} \end{array}$$

$$\|t - \phi(x)w\|_2^2 \quad \text{en nuestro caso} \quad J(w) = \|t - \phi w^T\|_2^2$$

$$\|t - \phi w^T\|_2^2 = \langle t_n - \phi w^T, t_n - \phi w^T \rangle$$

$$= (t_n - \phi w^T)^T \cdot (t_n - \phi w^T) = (t_n^T - (\phi w^T)^T) \cdot (t_n - \phi w^T)$$

$$= t_n^T t_n - \underbrace{t_n^T (\phi w^T) - (\phi w^T)^T t_n}_{-2 t_n (\phi w^T)^T} + (w^T \phi)^T (\phi w^T)$$

Minimizar la función de costo $\text{argmin}(J(w))$ Igualar a 0

$$\frac{\partial J(w)}{\partial w} = t_h^T t_h - 2t^T \phi w^T + (w^T \phi)^T (\phi w^T) = 0$$

$$\frac{\partial J(w)}{\partial w} = t_h^T t_h - 2t^T \phi w^T + w \phi^T \phi w^T$$

$$0 - 2t^T \phi + 2w \phi^T \phi = 0$$

$$2w \phi^T \phi = 2t^T \phi$$

$$w = t^T \phi (\phi^T \phi)^{-1}$$

Mínimos Cuadrados Regularizados

función de costo a utilizar $\|y - \phi w^T\|_2^2 + I \lambda \|w\|_2^2$

$y = t$ en nuestro caso

$$\langle a, a \rangle = a^T a$$

$$\langle (t - \phi w^T), (t - \phi w^T) \rangle = (t - \phi w^T)^T \cdot (t - \phi w^T)$$

$$I \lambda \langle w, w \rangle = I \lambda (w^T \cdot w)$$

$$(t - \phi w^T)^T \cdot (t - \phi w^T) + I \lambda (w^T w)$$

$$t^T t - \underbrace{t^T \phi w^T + t \phi^T w}_{-2t^T \phi w^T} + \phi^T w \phi w^T + I \lambda w^T w$$

$$J(w) = t^T t - 2t^T \phi w^T + \phi^T w \phi w^T + I \lambda w^T w$$

Minimizamos función de costo $J(w)$

$$\frac{\partial J(w)}{\partial w} = 0 \Rightarrow 0 - 2t^T \phi + 2w \phi^T \phi + 2I \lambda w = 0$$

$$2w \phi^T \phi + 2I \lambda w = 2t^T \phi$$

$$w \phi^T \phi + I \lambda w = t^T \phi$$

$$w (\phi^T \phi + I \lambda) = t^T \phi$$

$$w = t^T \phi (\phi^T \phi + I \lambda)^{-1}$$

Maxima Verosimilitud

Objetivo: Maximiza la función de verosimilitud (L)

$$\hat{\theta} = \arg \max_{\theta} L(\theta; x)$$

← datos
← parámetro

$$t_n = \phi(x_n) w^T + \eta \quad \eta = t_n - \phi(x_n) w^T$$

$$\eta \sim N(0, \sigma_{\eta}^2) \rightarrow N(\eta | \mu_{\eta}, \sigma_{\eta}^2) \quad \mu_{\eta} = 0$$

función de verosimilitud para este caso \Rightarrow

$$P(t_n | \phi(x_n) w^T, \sigma_{\eta}^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(t_n - \phi(x_n) w^T)^2}{2\sigma^2}\right)$$

Dado probabilidad conjunta y utilizando Log-verosimilitud \Rightarrow

$$L(w) = \prod_{n=1}^N p(t_n | \phi(x_n)w^T, \sigma^2)$$

$$\log L(w) = \sum_{n=1}^N \log p(t_n | \phi(x_n)w^T, \sigma^2)$$

$$\log L(w) = -\frac{N}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=1}^N (t_n - \phi(x_n)w^T)^2$$

$$\cancel{\frac{-N}{2} \log(2\pi\sigma^2)} \rightarrow \text{constante} - \frac{1}{2\sigma^2} \sum_{n=1}^N \|t - \phi w\|_2^2 \rightarrow -2t^T \phi w^T + w \phi^T \phi w^T$$

Se deriva respecto a w $\frac{\partial L}{\partial w} = 0$

$$\frac{-1}{2\sigma^2} \sum_{n=1}^N (t_n - \phi(x_n)w^T)^2$$

$$\frac{-1}{2\sigma^2} \sum_{n=1}^N 2(t_n - \phi(x_n)w^T)(-\phi(x_n))$$

$$\frac{1}{\sigma^2} \sum_{n=1}^N (t_n - \phi(x_n)w^T)(\phi(x_n)) = 0$$

$$\sum_{n=1}^N t_n \phi(x_n) - \sum_{n=1}^N \phi(x_n)w^T \phi(x_n) = 0$$

$$\sum_{n=1}^N t_n \phi(x_n) = \sum_{n=1}^N \phi(x_n)w^T \phi(x_n) \rightarrow \phi(x_n)^T = \phi(x_n)^T \phi(x_n)$$

$$\rightarrow t^T \phi = w \phi^T \phi \quad w = t^T \phi (\phi^T \phi)^{-1}$$

Máximo a Posteriori (MAP)

$$w_{\text{map}} = \arg \max_w p(w|t) \rightarrow p(t|w) p(w) = p(w|t) p(t)$$

El posterior $p(w|t) = \frac{p(t|w) p(w)}{p(t)} \rightarrow \text{Likelihood}$
 $\rightarrow \text{Prior}$

Sabemos que

$$p(t_n | \phi(x_n) w^T, \sigma_h^2) = N(t_n | \phi(x_n) w^T, \sigma_h^2)$$

$$w_{\text{map}} = \arg \max_w \log \left(\prod_{n=1}^N N(t_n | \phi(x_n) w^T, \sigma_h^2) \prod_{q=1}^Q N(w_q | \phi, \sigma_w^2) \right)$$

$$w_{\text{map}} = \arg \max_w - \frac{1}{2\sigma_h^2} \|t - \Phi w^T\|_2^2 - \frac{1}{2\sigma_w^2} \|w\|_2^2$$

$$\lambda = \frac{\sigma_h^2}{\sigma_w^2}$$

$$w = t^T \phi (\phi^T \phi + \mathbb{I} \lambda)^{-1}$$

Diferencias

Mínimos Cuadrados

Minimiza la suma de los cuadrados de los errores
Sensible al sobreajuste

Mínimos Cuadrados Regularizados

Mínimos Cuadrados Regularizados, penaliza
complejidad del modelo

Máxima Verosimilitud

Maximiza función de verosimilitud de los datos
dados parámetros, propenso a sobreajuste

MAP

Maximiza Probabilidad posterior, considerando
prior y likelihood